

TRƯỜNG ĐẠI HỌC FPT
FPT UNIVERSITY ĐÀ NẴNG

BÁO CÁO CUỐI KỲ

**NHẬN DIỆN BIỂN BÁO GIAO THÔNG
VIỆT NAM**

**BẰNG CÁC PHƯƠNG PHÁP TRÍCH XUẤT ĐẶC
TRUNG VÀ MÔ HÌNH HỌC MÁY**

Môn học:	AIL303m
Học kỳ:	Summer 2026
Giảng viên hướng dẫn:	Võ Quốc Trình
Nhóm thực hiện:	6
Danh sách thành viên:	Lê Khôi Nguyên (SE200064), Bùi Anh Kiệt (DE200465), Trương Phước Nguyên (DE190562), Phan Hữu Nhật Trường (DE200114)

Đà Nẵng, tháng 7 năm 2026

TÓM TẮT

Báo cáo trình bày quá trình xây dựng, kiểm chứng và tối ưu một hệ thống phân loại biển báo giao thông Việt Nam trên bộ dữ liệu NVTS gồm 47 lớp. Bài toán có ba thách thức nổi bật: nhiều lớp có hình dạng và màu sắc gần giống nhau, ảnh thực tế chịu ảnh hưởng của mờ, chiếu sáng và biến dạng góc nhìn, và phân bố lớp mất cân bằng nghiêm trọng khi 10 lớp có dưới 30 ảnh train. Mục tiêu của dự án là đồng thời đạt hiệu năng phân loại cao, cải thiện khả năng nhận diện lớp hiếm và duy trì độ trễ thấp trên nền tảng học máy cổ điển, không phụ thuộc vào mô hình học sâu công kênh. Pipeline cuối cùng chuẩn hóa ảnh về 64×64 bằng `pad_square`; trích xuất HOG trên ảnh xám để mô tả hình dạng và cạnh; xây dựng Color Histogram trong không gian HSV để mô tả màu; dung hợp hai đặc trưng; chuẩn hóa bằng `StandardScaler`; giảm chiều bằng PCA giữ 95% phương sai; tăng cường dữ liệu trực tiếp trên ảnh cho các lớp thiểu số; và phân loại bằng SVC kernel tuyến tính. Sau các ablation về kích thước ảnh, không gian màu, PCA và augmentation, dự án benchmark sáu họ mô hình và khảo sát các kernel SVM. Cấu hình cuối là `SVC(kernel="linear", C=0,1, class_weight=None)`. Trên tập test 851 ảnh, mô hình đạt Accuracy 96,12%, Macro Precision 97,51%, Macro Recall 95,62%, Macro F1 96,29% và Weighted F1 96,09%. Thời gian 1,52 ms/ảnh là độ trễ của bước phân loại trên vector đặc trưng đã được xử lý, không phải latency end-to-end. So với RBF ở Phase 1, Linear SVM tăng Macro F1 0,65 điểm phần trăm và Macro Recall 1,23 điểm phần trăm, đồng thời giảm 817 support vector. Kết quả cho thấy một pipeline đặc trưng được thiết kế phù hợp có thể tạo ra không gian phân loại chất lượng cao, trong đó mô hình tuyến tính vừa cạnh tranh về hiệu năng vừa thuận lợi cho triển khai tài nguyên hạn chế.

Từ khóa: nhận diện biển báo giao thông, HOG, HSV Histogram, PCA, mất cân bằng lớp, Linear SVM, học máy truyền thống.

Thông điệp chính

Kết quả tốt nhất không đến từ việc tăng độ phức tạp của mô hình, mà đến từ sự phối hợp giữa biểu diễn hình dạng, màu sắc, giảm chiều và quy trình lựa chọn mô hình dựa trên Macro F1.

MỤC LỤC

TÓM TẮT	1
DANH MỤC TỪ VIẾT TẮT	5
1. GIỚI THIỆU	5
1.1. Bối cảnh nghiên cứu	5
1.2. Phát biểu bài toán và phạm vi	6
1.3. Mục tiêu nghiên cứu	6
1.4. Câu hỏi nghiên cứu	6
1.5. Đóng góp chính	7
2. CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN	7
2.1. Pipeline nhận diện biển báo bằng đặc trưng thủ công	7
2.2. Histogram of Oriented Gradients	7
2.3. Color Histogram trong không gian HSV	8
2.4. PCA và giảm chiều	8
2.5. Support Vector Machine	8
2.6. Đánh giá trên dữ liệu mất cân bằng	9
2.7. Nghiên cứu liên quan	9
3. DỮ LIỆU VÀ PHÂN TÍCH MẤT CÂN BẰNG	9
3.1. Bộ dữ liệu NVTs	9
3.2. Các lớp thiểu số nghiêm trọng	11
3.3. Đặc điểm và giới hạn dữ liệu	12
4. PHƯƠNG PHÁP ĐỀ XUẤT	13
4.1. Chiến lược thực nghiệm hai giai đoạn	13
4.2. Tiền xử lý hình học	13
4.3. Đặc trưng HOG Gray	14
4.4. Color Histogram HSV	14
4.5. Dung hợp đặc trưng	14
4.6. StandardScaler và PCA	14
4.7. Tăng cường dữ liệu cho lớp hiếm	15
4.8. Bộ phân loại cuối cùng	15

5. THIẾT KẾ THỰC NGHIỆM	15
5.1. Quy tắc fit và transform	15
5.2. Chỉ số đánh giá	16
5.3. Ma trận thực nghiệm	16
5.4. Audit việc sử dụng tập test	16
5.5. Phạm vi của phép đo độ trễ	17
6. KẾT QUẢ THỰC NGHIỆM	17
6.1. Kích thước ảnh và chế độ resize (M02)	17
6.2. Không gian màu và dung hợp đặc trưng (M03)	18
6.3. Tác động của PCA và augmentation (M04)	18
6.4. Benchmark sáu họ mô hình (M05)	19
6.5. Khảo sát kernel và siêu tham số SVM (M06)	19
6.6. Kết quả chung cuộc và trade-off	21
6.7. Phân tích nhóm lỗi còn lại	22
7. THẢO LUẬN	23
7.1. Vì sao HOG và HSV bổ sung cho nhau?	23
7.2. Vai trò thực nghiệm của PCA	23
7.3. Vì sao Linear SVM tốt hơn RBF trong pipeline này?	24
7.4. Vì sao Random Forest và LightGBM thấp hơn?	24
7.5. Hạn chế của KNN trong 571 chiều	24
7.6. Ý nghĩa của việc tăng Macro Recall	24
7.7. Khả năng triển khai	25
8. HẠN CHẾ VÀ ĐỀ DỌA TÍNH HỢP LỆ	25
8.1. Hạn chế dữ liệu	25
8.2. Hạn chế protocol	25
8.3. Hạn chế tái lập và nhất quán artifact	26
9. HƯỚNG PHÁT TRIỂN	26
10. KẾT LUẬN	26
TÀI LIỆU THAM KHẢO	27
PHỤ LỤC A. CẤU HÌNH CUỐI CÙNG CỦA HỆ THỐNG	28

PHỤ LỤC B. BẢNG KIỂM SOÁT TÍNH NHẤT QUÁN	28
PHỤ LỤC C. ARTIFACT NỘI BỘ PHỤC VỤ TÁI LẬP	29
C.1. Checklist tái lập trước khi nộp	30

DANH MỤC TỪ VIẾT TẮT

Viết tắt	Nội dung
ADAS	Advanced Driver Assistance Systems - Hệ thống hỗ trợ người lái nâng cao
HOG	Histogram of Oriented Gradients
HSV	Hue - Saturation - Value
PCA	Principal Component Analysis
SVM/SVC	Support Vector Machine / Support Vector Classifier
RBF	Radial Basis Function
KNN	K-Nearest Neighbors
MLP	Multi-layer Perceptron
NVTS	Vietnamese Traffic Sign Dataset

1. GIỚI THIỆU

1.1. Bối cảnh nghiên cứu

Nhận diện biển báo giao thông là một thành phần quan trọng trong các hệ thống hỗ trợ người lái, giám sát giao thông và nền tảng giao thông thông minh. Một hệ thống đáng tin cậy phải phân biệt được nhiều loại biển có hình dạng, màu sắc và biểu tượng gần giống nhau, đồng thời duy trì tốc độ xử lý đủ nhanh trong điều kiện ảnh có thể bị mờ, thiếu sáng, lệch phối cảnh, che khuất hoặc suy giảm độ phân giải. Các nghiên cứu trước cho thấy đặc trưng hình dạng như HOG có khả năng biểu diễn tốt cấu trúc cạnh của biển báo, trong khi thông tin màu giúp phân biệt các nhóm biển cấm, cảnh báo và chỉ dẫn [2], [3].

Học sâu hiện là hướng chủ đạo trong nhiều bài toán thị giác máy tính, nhưng thường cần lượng dữ liệu gán nhãn lớn, tài nguyên huấn luyện cao và quá trình giải thích mô hình phức tạp hơn. Trong phạm vi môn AIL303m và mục tiêu xây dựng một hệ thống nhẹ, dự án lựa chọn classical computer vision kết hợp machine learning. Cách tiếp cận này cho phép đánh giá riêng tác động của tiền xử lý, đặc trưng, giảm chiều và bộ phân loại; đồng thời phù hợp với các môi trường không có GPU.

1.2. Phát biểu bài toán và phạm vi

Đầu vào của hệ thống là một ảnh đã được crop, trong đó mỗi ảnh chứa một biển báo giao thông. Nhiệm vụ là gán ảnh vào một trong 47 lớp của bộ dữ liệu NVTs. Phạm vi hiện tại là phân loại biển báo, chưa bao gồm bước phát hiện vị trí biển trong ảnh đường phố hoàn chỉnh. Vì vậy, kết quả của báo cáo phản ánh năng lực nhận diện trên ảnh đã crop và không được diễn giải như hiệu năng end-to-end của một hệ thống phát hiện - nhận diện hoàn chỉnh.

Dữ liệu gồm 6.605 ảnh train, 824 ảnh validation và 851 ảnh test. Thách thức quan trọng là mất cân bằng lớp: 10 lớp có dưới 30 ảnh train, trong đó R.301e chỉ có 16 ảnh và W.205c có 17 ảnh. Nếu chỉ tối ưu Accuracy, mô hình có thể ưu tiên các lớp phổ biến và vẫn đạt tỷ lệ đúng cao dù bỏ sót lớp hiếm. Vì vậy, Macro F1 được chọn làm metric chính.

1.3. Mục tiêu nghiên cứu

- Tìm cấu hình tiền xử lý ảnh giữ được hình học đặc trưng của biển báo và có chi phí tính toán hợp lý.
- Xây dựng biểu diễn kết hợp thông tin hình dạng và màu sắc bằng HOG Gray và HSV Color Histogram.
- Đánh giá tác động của StandardScaler và PCA đối với hiệu năng, số chiều và độ trễ.
- Cải thiện khả năng nhận diện lớp hiếm bằng tăng cường dữ liệu trực tiếp trên ảnh train.
- Benchmark nhiều họ mô hình học máy và tinh chỉnh SVM để tìm cấu hình cuối cùng tốt nhất.
- Đánh giá mô hình bằng Accuracy, Macro Precision, Macro Recall, Macro F1, Weighted F1 và thời gian suy luận.

1.4. Câu hỏi nghiên cứu

1. Kết hợp HOG và HSV Histogram có tạo ra biểu diễn hiệu quả hơn khi xét trong pipeline hoàn chỉnh hay không?
2. PCA có thể giảm mạnh số chiều mà vẫn duy trì hoặc cải thiện Macro F1 hay không?
3. Tăng cường dữ liệu cho lớp hiếm có cải thiện Macro Recall và Macro F1 hay không?

4. Sau khi đặc trưng được chuẩn hóa và giảm chiều, mô hình tuyến tính hay phi tuyến phù hợp hơn?
5. Độ trễ được báo cáo có ý nghĩa như thế nào đối với khả năng triển khai thời gian thực?

1.5. Đóng góp chính

6. Một pipeline hoàn chỉnh gồm 64×64 pad_square, HOG Gray, HSV Histogram, StandardScaler, PCA 95%, minority augmentation và Linear SVM.
7. Một quy trình thực nghiệm hai giai đoạn: Phase 1 khóa mô hình để đánh giá feature engineering; Phase 2 benchmark và tuning mô hình.
8. Một giải pháp xử lý lớp hiếm bằng augmentation ảnh 2D, bổ sung 430 ảnh train mà không nội suy trực tiếp trong không gian HOG.
9. Một phân tích đầy đủ về trade-off giữa Accuracy, Macro Precision, Macro Recall, Macro F1, độ trễ và số support vector.
10. Một phần audit khoa học chỉ rõ giới hạn của protocol test, latency và sự chưa thống nhất của số chiều đặc trưng trong các artifact.

2. CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN

2.1. Pipeline nhận diện biển báo bằng đặc trưng thủ công

Pipeline truyền thống cho nhận diện biển báo thường gồm tiền xử lý, trích xuất đặc trưng và phân loại. Chất lượng biểu diễn ảnh quyết định đáng kể đến khả năng phân tách của mô hình. Với biển báo, hai nguồn thông tin quan trọng là hình dạng - cạnh và màu sắc. HOG mô tả cấu trúc gradient; histogram màu mô tả phân bố sắc độ; bộ phân loại sau đó hoạt động trên vector đặc trưng thay vì pixel thô.

2.2. Histogram of Oriented Gradients

HOG do Dalal và Triggs giới thiệu để mô tả phân bố hướng gradient trong các vùng cục bộ [2]. Ảnh được chia thành các cell; mỗi cell tích lũy histogram của hướng gradient, có trọng số theo độ lớn gradient; các cell lân cận được chuẩn hóa theo block. HOG bền vững hơn pixel thô trước một số thay đổi chiếu sáng và đặc biệt phù hợp với biển báo vì chúng có đường viền

manh, hình học rõ và biểu tượng tương phản cao.

Trong dự án, HOG được trích xuất trên ảnh grayscale với orientations=9, pixels_per_cell=(8,8), cells_per_block=(2,2) và block_norm=L2-Hys. Các thông số này được dùng làm mô tả cấu hình; tuy nhiên số chiều tổng 1.812 trong artifact M04 chưa khớp hoàn toàn với phép tính lý thuyết từ các tham số được ghi lại. Báo cáo giữ nguyên giá trị artifact và đưa vấn đề này vào phần hạn chế thay vì tự suy diễn.

2.3. Color Histogram trong không gian HSV

Không gian HSV tách sắc độ Hue khỏi độ bão hòa Saturation và độ sáng Value. Điều này thuận lợi khi mô tả màu biển báo vì các nhóm biển thường tuân theo quy ước màu tương đối ổn định: đỏ cho nhiều biển cấm, vàng cho cảnh báo, xanh cho chỉ dẫn. Histogram 3D với 8 bin mỗi kênh tạo 512 bin và được chuẩn hóa theo tổng khối lượng. Histogram không giữ vị trí không gian chi tiết, nhưng cung cấp tín hiệu màu tổng thể bổ sung cho HOG.

2.4. PCA và giảm chiều

Khi nhiều đặc trưng được nối với nhau, số chiều tăng nhanh và có thể chứa nhiều thành phần tương quan hoặc dư thừa. PCA biến đổi dữ liệu sang hệ trục trực giao được sắp theo phương sai giảm dần. Trong dự án, Standard-Scaler được fit trên train trước PCA; PCA giữ 95% phương sai và giảm vector cuối xuống 571 chiều. PCA không trực tiếp tối ưu nhân lớp và không phải lúc nào cũng là bộ lọc nhiễu; hiệu quả của nó phải được xác nhận bằng thực nghiệm.

2.5. Support Vector Machine

SVM tìm siêu phẳng có lề phân cách lớn giữa các lớp. Với soft margin, mô hình cho phép một số điểm vi phạm lề để cải thiện khả năng khái quát. Bài toán nhị phân có thể viết dưới dạng:

$$\min_{w,b,\xi} \left(\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \right) \quad (1)$$

với các ràng buộc:

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \text{và} \quad \xi_i \geq 0, \quad \forall i = 1, 2, \dots, n \quad (2)$$

Tham số C điều khiển đánh đổi giữa lề rộng và mức phạt vi phạm. Kernel

tuyến tính phù hợp khi dữ liệu có thể phân tách tốt trong không gian hiện tại; RBF cho ranh giới linh hoạt hơn nhưng đòi hỏi tuning C và gamma. Với bài toán đa lớp, SVC xây dựng nhiều bài toán nhị phân nội bộ. Trong dự án, cấu hình Linear SVM với $C=0,1$ cho validation Macro F1 cao nhất.

2.6. Đánh giá trên dữ liệu mất cân bằng

Accuracy đo tỷ lệ dự đoán đúng trên toàn bộ mẫu, nhưng có thể che khuất hiệu năng kém của lớp hiếm. Macro Precision, Macro Recall và Macro F1 tính metric riêng cho từng lớp rồi lấy trung bình không trọng số; do đó mỗi lớp đóng góp ngang nhau. Weighted F1 được báo cáo bổ sung để phản ánh hiệu năng theo phân bố mẫu thực tế. Dự án chọn Macro F1 làm tiêu chí chính để cân bằng giữa precision và recall trên 47 lớp.

2.7. Nghiên cứu liên quan

Ma và Huang đề xuất hệ thống nhận diện biển báo phân cấp coarse-to-fine, kết hợp HOG ở tầng thô và Dense-SIFT, LBP, Gabor cùng committee SVM - Random Forest ở tầng chi tiết. Phương pháp đạt 98,76% Accuracy trên GTSRB và khoảng 50 ms/ảnh trên phần cứng được báo cáo [3]. Công trình này củng cố hai nhận định: đặc trưng bổ sung có thể tăng hiệu năng và chiến lược phân cấp phù hợp với các lớp có ngoại hình gần giống nhau. Tuy nhiên, không thể so sánh trực tiếp con số 98,76% với kết quả NVTS của dự án vì bộ dữ liệu, số lớp, kích thước train/test, protocol và phần cứng khác nhau.

GTSRB là benchmark lớn với 43 lớp và hơn 50 nghìn ảnh, thường được dùng để so sánh các hệ thống nhận diện biển báo [4]. Dự án hiện tại tập trung vào NVTS 47 lớp và mục tiêu lightweight classical ML. Vì vậy, related work được dùng để định hướng thiết kế và thảo luận, không dùng để khẳng định superiority tuyệt đối.


3. DỮ LIỆU VÀ PHÂN TÍCH MẤT CÂN BẰNG

3.1. Bộ dữ liệu NVTS


Dự án sử dụng bộ dữ liệu biển báo giao thông Việt Nam NVTS gồm 47 lớp. Ảnh đã được crop theo biển báo và được tổ chức thành train, validation và test. Train được dùng để fit scaler, PCA và mô hình; validation dùng để lựa chọn cấu hình và siêu tham số; test dùng cho các đánh giá được artifact ghi nhận. Sau tăng cường, train tăng từ 6.605 lên 7.035 ảnh.

Tập dữ liệu	Số lớp	Số ảnh	Vai trò
Train gốc	47	6.605	Huấn luyện bộ biến đổi và mô hình
Validation	47	824	So sánh cấu hình và chọn siêu tham số
Test	47	851	Đánh giá theo các artifact dự án
Train sau tăng cường	47	7.035	Train cuối sau bổ sung 430 ảnh lớp hiếm

Bảng 1. Quy mô và vai trò của các tập dữ liệu.



Hình 1. Quy mô các tập dữ liệu sử dụng trong dự án.



Hình 2. Một số mẫu ảnh biển báo giao thông Việt Nam sau khi crop từ bộ dữ liệu NVTS.

Hình 2 cho thấy tập dữ liệu bao gồm nhiều nhóm biển khác nhau như chỉ hướng, cấm, hiệu lệnh và cảnh báo. Các mẫu sau crop có sự khác biệt về kích thước vùng biển trong khung hình, độ sắc nét, ánh sáng, góc nhìn và mức độ nhiễu nền. Điều này giải thích vì sao pipeline cần kết hợp đồng thời thông tin hình dạng và màu sắc, thay vì chỉ dựa vào một loại đặc trưng đơn lẻ.


3.2. Các lớp thiếu số nghiêm trọng

Phân tích M01 xác định 10 lớp có dưới 30 ảnh train. Đây là các lớp có rủi ro cao do biến thiên trong validation/test có thể không được đại diện đầy đủ trong train. Danh sách này được sử dụng nhất quán trong bước augmentation ở M04.

Nhãn lớp	Số ảnh train gốc
R.301e	16
W.205c	17
I.409	20
S.505a Xe máy	20

Nhãn lớp	Số ảnh train gốc
S.505a Xe tải	21
W.239b_	21
P.124d	23
W.203c	23
W.205a	26
W.225	28

Bảng 2. Mười lớp có dưới 30 ảnh train.



Hình 2. Phân bố số ảnh của 10 lớp thiếu số.


Augmentation cải thiện rõ một số lớp nhưng không thể thay thế dữ liệu thật. Đặc biệt, W.205c chỉ có 17 ảnh train và vẫn là lớp khó trong một số đánh giá. Báo cáo không khẳng định toàn bộ các lớp hiếm đều đạt Recall hoặc F1 cao; kết quả tổng hợp phải được đọc cùng phân tích per-class.

3.3. Đặc điểm và giới hạn dữ liệu

- Ảnh đầu vào đã crop, do đó chưa phản ánh sai số của bước phát hiện biển báo trong cảnh đường phố.
- Một số lớp chỉ khác nhau ở chi tiết rất nhỏ như chữ số hoặc hướng mũi tên; độ phân giải thấp làm giảm khả năng phân biệt.
- Phân bố lớp mất cân bằng khiến metric per-class của lớp hiếm có phương sai cao.

- Hiện chỉ có một cách chia train/validation/test được báo cáo; chưa có repeated stratified cross-validation cho toàn pipeline.

4. PHƯƠNG PHÁP ĐỀ XUẤT



Tăng cường ảnh 2D cho 10 lớp hiếm được thực hiện trên train trước bước trích xuất đặc trưng M04; cần audit mã nguồn để đối chiếu phân rã số chiều.

Hình 3. Pipeline cuối cùng của hệ thống nhận diện.

4.1. Chiến lược thực nghiệm hai giai đoạn

Phase 1 khóa bộ phân loại ở cấu hình SVC RBF, $C=10$, $\gamma=\text{scale}$ và $\text{class_weight}=\text{balanced}$. Việc cố định mô hình giúp cô lập ảnh hưởng của kích thước ảnh, chế độ resize, không gian màu, dung hợp đặc trưng, PCA và augmentation. Sau khi chốt không gian đặc trưng, Phase 2 benchmark nhiều thuật toán và tinh chỉnh kernel, C , γ và class_weight . Cách tổ chức này hạn chế việc gán nhầm cải thiện do model tuning cho feature engineering hoặc ngược lại.

4.2. Tiền xử lý hình học

M02 khảo sát 32×32 , 48×48 và 64×64 với hai chế độ stretch và pad_square. Trong ablation HOG Gray độc lập, 48×48 stretch đạt Validation Macro F1 cao nhất 95,95%. Tuy nhiên, pipeline tích hợp M04/M06 sử dụng 64×64 pad_square cùng HOG, histogram màu, PCA và augmentation. Pad_square đệm ảnh về hình vuông trước khi resize, nhờ đó hạn chế làm méo hình tròn, tam giác và chữ nhật. Báo cáo ghi nhận rõ sự khác biệt giữa “cấu hình tốt nhất trong ablation riêng” và “cấu hình cuối của pipeline”.

4.3. Đặc trưng HOG Gray

Ảnh được chuyển sang grayscale trước khi tính HOG. Gradient ngang và dọc được ước lượng tại từng pixel; độ lớn và góc gradient được tổng hợp thành histogram hướng trong các cell, sau đó chuẩn hóa theo block. Cấu hình được ghi nhận gồm 9 hướng, $\text{pixels_per_cell}=(8,8)$, $\text{cells_per_block}=(2,2)$ và $\text{block_norm}=\text{L2-Hys}$. HOG tập trung vào đường viền, góc và cấu trúc biểu tượng nên phù hợp để phân biệt hình học của biển báo.

4.4. Color Histogram HSV

Song song với HOG, ảnh màu được chuyển sang HSV và xây dựng histogram ba chiều với 8 bin cho mỗi kênh, tạo 512 bin. Histogram được chuẩn hóa để giảm ảnh hưởng của cường độ tổng. So với tính HOG trên nhiều kênh màu, histogram HSV cung cấp tín hiệu màu gọn hơn và tránh mở rộng quá lớn số chiều gradient.

4.5. Dung hợp đặc trưng

Vector HOG và HSV Histogram được nối theo chiều cột. Artifact nghiệm thu M04 ghi nhận vector sau dung hợp có 1.812 chiều. Do giá trị này chưa khớp hoàn toàn với phép tính lý thuyết từ bộ tham số HOG được mô tả, báo cáo sử dụng con số 1.812 như giá trị thực nghiệm và không công bố decomposition chi tiết khi chưa audit trực tiếp mã nguồn final. Đây là lựa chọn thận trọng nhằm tránh tạo ra thông tin có vẻ chính xác nhưng không được chứng minh.

4.6. StandardScaler và PCA

StandardScaler chỉ được fit trên train để đưa mỗi chiều về trung bình 0 và độ lệch chuẩn 1. Cùng scaler đó được dùng để transform validation và test. PCA cũng chỉ fit trên train, giữ 95% phương sai. Sau biến đổi, số chiều pipeline cuối là 571. Quy tắc fit trên train giúp tránh data leakage từ validation/test vào bộ biến đổi.

Trong M04, PCA giảm thời gian inference từ 5,93 ms/ảnh xuống 1,91 ms/ảnh ở cấu hình validation, trong khi Macro F1 tăng từ 94,85% lên 95,04%. Kết quả này cho thấy PCA vừa giảm chi phí tính toán vừa có tác dụng regularization thực nghiệm trên bộ đặc trưng cụ thể.

4.7. Tăng cường dữ liệu cho lớp hiếm

Đối với 10 lớp có dưới 30 ảnh train, nhóm áp dụng xoay nhẹ khoảng $\pm 10^\circ$ và điều chỉnh độ sáng khoảng $\pm 15\%$ trên ảnh 2D trước khi trích xuất đặc trưng. Tổng số ảnh train tăng thêm 430. Cách làm này đảm bảo mỗi mẫu mới tương ứng với một ảnh có ý nghĩa vật lý và HOG được tính lại từ cấu trúc cạnh sau biến đổi.

SMOTE không được dùng trong pipeline cuối. Trong không gian HOG, nội suy tuyến tính giữa hai vector có thể tạo mẫu không tương ứng với một ảnh cụ thể. Điều này không có nghĩa SMOTE luôn không phù hợp, nhưng augmentation ảnh là lựa chọn dễ kiểm soát và diễn giải hơn cho dự án.

4.8. Bộ phân loại cuối cùng

Sau benchmark và tuning, mô hình được chọn là SVC(kernel="linear", C=0.1, class_weight=None). C=0,1 tạo regularization mạnh hơn các giá trị C lớn, cho phép một số điểm vi phạm lề để giảm nhạy với outlier. Ba chiến lược class_weight None, balanced và custom cho cùng Validation Macro F1 97,30%; vì vậy None được chọn do đơn giản hơn và cho thấy augmentation đã giảm nhu cầu điều chỉnh trọng số lớp trong split hiện tại.

5. THIẾT KẾ THỰC NGHIỆM

5.1. Quy tắc fit và transform

- Augmentation chỉ áp dụng trên train; validation và test không được tăng cường.
- StandardScaler và PCA được fit trên train rồi mới transform validation/test.
- Lựa chọn kernel và siêu tham số M06 dựa trên Validation Macro F1.
- Macro F1 là metric chính; Accuracy và các metric còn lại dùng để giải thích trade-off.
- Thời gian inference được chuẩn hóa theo ms/ảnh và cần ghi rõ phạm vi đo.

5.2. Chỉ số đánh giá

$$\text{Precision}_k = \frac{\text{TP}_k}{\text{TP}_k + \text{FP}_k} \quad (3)$$

$$\text{Recall}_k = \frac{\text{TP}_k}{\text{TP}_k + \text{FN}_k} \quad (4)$$

$$\text{F1}_k = \frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k} \quad (5)$$

$$\text{Macro F1} = \frac{1}{K} \sum_{k=1}^K \text{F1}_k \quad (6)$$

Macro F1 cho trọng số ngang nhau cho 47 lớp và được dùng làm tiêu chí lựa chọn chính. Macro Recall đặc biệt hữu ích để quan sát mức bỏ sót các lớp khó, còn Macro Precision phản ánh số false positive. Weighted F1 và Accuracy giúp mô tả hiệu năng theo phân bố mẫu thực tế.

5.3. Ma trận thực nghiệm

Nhiệm vụ	Mục tiêu	Thành phần chính
M01	Chẩn đoán dữ liệu và lớp hiếm	Phân bố lớp, bottleneck, nhóm lỗi
M02	Tối ưu kích thước và resize	32/48/64; stretch/pad_square
M03	Khảo sát đặc trưng màu và fusion	HOG Gray, HOG YUV, HOG + HSV
M04	Đánh giá PCA và augmentation	Không PCA; PCA; PCA + augmentation
M05	Benchmark mô hình	SVC, RF, LightGBM, LR, KNN, MLP
M06	Fine-tuning SVM	Kernel, C, gamma, class_weight

Bảng 3. Cấu trúc nhiệm vụ thực nghiệm của dự án.

5.4. Audit việc sử dụng tập test

Lưu ý về tính hợp lệ của protocol

Các artifact hiện có đã ghi nhận test metric ở Phase 1 và M05 trước khi báo cáo kết quả M06. Vì vậy, không nên mô tả tập test như một blind holdout chỉ được truy cập đúng một lần trong toàn bộ vòng đời dự án. Việc chọn cấu hình M06 dựa trên validation giúp giảm rủi ro overfit trực tiếp vào test, nhưng repeated observation vẫn là một đe dọa tính hợp lệ. Phiên bản tiếp theo nên khóa test, dùng validation/cross-validation cho toàn bộ lựa chọn và chỉ mở test sau khi pipeline được đóng băng.

5.5. Phạm vi của phép đo độ trễ

Con số 1,52 ms/ảnh trong final result phản ánh thời gian dự đoán của classifier trên vector đã được StandardScaler/PCA xử lý theo artifact M06. Nó chưa bao gồm đọc ảnh, pad_square, resize, HOG, HSV Histogram, scaler và PCA. Do đó không nên quy đổi trực tiếp thành FPS end-to-end. Muốn đánh giá triển khai thực tế, cần profiling từng bước trên cùng phần cứng mục tiêu.

6. KẾT QUẢ THỰC NGHIỆM**6.1. Kích thước ảnh và chế độ resize (M02)**

Cấu hình	Số chiều HOG	Val Accuracy (%)	Val Macro F1 (%)	Train (s)
32×32 stretch	1.764	95,15	92,16	18,51
32×32 pad_square	1.764	94,90	92,19	15,72
48×48 stretch	900	96,48	95,95	5,84
48×48 pad_square	900	96,12	94,56	5,87
64×64 stretch	1.764	95,87	94,04	13,07
64×64 pad_square	1.764	95,51	93,44	13,52

Bảng 4. Kết quả khảo sát kích thước và chế độ resize ở M02 [5].

48×48 stretch đạt Macro F1 cao nhất trong ablation HOG Gray. Kết quả cho thấy tăng kích thước không tự động làm hiệu năng tăng; số chiều lớn hơn có thể thêm nhiễu và tăng chi phí. Tuy nhiên, bảng này chưa đánh giá

toàn bộ pipeline có màu, PCA và augmentation nên không trực tiếp quyết định cấu hình final.

6.2. Không gian màu và dung hợp đặc trưng (M03)

Đặc trưng	Số chiều	Val Accuracy (%)	Val Macro F1 (%)	Train (s)
HOG Gray	900	96,48	95,95	6,33
HOG YUV	2.700	96,36	94,75	25,60
HOG Gray + HSV	1.412	95,87	95,19	9,08
Histogram				

Bảng 5. Kết quả khảo sát đặc trưng ở M03 [5].

HOG Gray đơn lẻ đạt F1 cao nhất trong ablation M03, còn HOG YUV vừa tăng số chiều vừa giảm F1. HOG + HSV chưa vượt HOG Gray ở cấu hình 48×48 riêng lẻ nhưng được giữ lại vì cung cấp thông tin màu bổ sung và cho kết quả tốt hơn khi kết hợp với cấu hình M04, PCA và augmentation. Điều này cho thấy không nên chọn thành phần chỉ dựa trên một thí nghiệm cô lập.

6.3. Tác động của PCA và augmentation (M04)

Cấu hình	Số chiều	Số ảnh train	Val Accuracy (%)	Val Macro F1 (%)	Inference (ms/ảnh)
TN3.1: Không PCA, không Aug	1.812	6.605	96,24	94,85	5,93
TN3.2: PCA 95%	569	6.605	96,60	95,04	1,91
TN3.3: PCA 95% + Aug	571	7.035	96,72	95,77	1,96


Bảng 6. Tác động của PCA và minority augmentation ở M04 [5].

PCA giảm khoảng 68,5% số chiều và làm inference nhanh hơn hơn ba lần trong ablation M04. Augmentation bổ sung 430 ảnh và nâng Macro F1 validation từ 95,04% lên 95,77%. Artifact Phase 1 ghi nhận mô hình RBF đạt Test Accuracy 96,24%, Test Macro F1 95,64% và 1,93 ms/ảnh.

6.4. Benchmark sáu họ mô hình (M05)

Mô hình	Train (s)	Inference (ms/ảnh)	Accuracy (%)	Macro F1 (%)	Minority Recall (%)
SVC RBF	3,5868	2,4520	95,77	95,37	86,67
Random Forest	2,6118	0,0310	85,78	84,74	75,00
LightGBM	40,4803	0,0373	87,78	86,70	80,83
Logistic Regression	1,2973	0,0027	95,77	94,82	89,17
KNN	0,0117	1,8068	94,83	94,23	87,50
MLP	2,9231	0,0018	95,18	93,62	87,50

Bảng 7. Benchmark sáu mô hình trên đặc trưng PCA 571 chiều [6].




Hình 4. So sánh Macro F1 của sáu họ mô hình trong artifact M05.

SVC RBF dẫn đầu benchmark; Logistic Regression đạt Accuracy tương đương và Macro F1 chỉ thấp hơn 0,55 điểm phần trăm. Đây là tín hiệu rằng không gian sau PCA phù hợp tốt với mô hình tuyến tính. Random Forest và LightGBM có inference nhanh nhưng F1 thấp hơn đáng kể; KNN và MLP cạnh tranh nhưng không vượt SVM.

6.5. Khảo sát kernel và siêu tham số SVM (M06)

Kernel / cấu hình	Val Accuracy (%)	Val Macro F1 (%)	Train (s)	Support vectors
Linear, C=0,1, class_weight=None	96,72	97,30	2,46	4.514
Linear, C=10, balanced	96,72	97,30	2,22	4.514
RBF, C=10, gamma=scale	96,72	95,77	6,25	5.331
RBF, C=5, gamma=0,0005	96,84	95,81	5,20	5.261
Polynomial degree 2	96,72	95,03	6,32	5.273
Polynomial degree 3	94,78	93,43	14,28	5.172
Sigmoid	94,05	92,96	2,35	3.812

Bảng 8. Kết quả khảo sát kernel SVM trên validation [6], [7].




Hình 5. Validation Macro F1 theo kernel SVM.

Linear SVM đạt Validation Macro F1 97,30%, cao hơn RBF baseline 1,53 điểm phần trăm. Nhiều giá trị C cho cùng metric validation, cho thấy nghiệm khá ổn định trên split này. C=0,1 được chọn theo nguyên tắc ưu tiên regularization mạnh hơn khi hiệu năng tương đương. Ba chiến lược class_weight cũng cho cùng F1, vì vậy class_weight=None được chọn.

6.6. Kết quả chung cuộc và trade-off

Chỉ số	Phase 1: RBF	Phase 2: Linear	Chênh lệch
Test Accuracy (%)	96,24	96,12	-0,12
Test Macro F1 (%)	95,64	96,29	+0,65
Test Macro Precision (%)	98,08	97,51	-0,57
Test Macro Recall (%)	94,39	95,62	+1,23
Test Weighted F1 (%)	96,15	96,09	-0,06
Classifier inference (ms/ảnh)	1,93	1,52	-0,41
Support vectors	5.331	4.514	-817


Bảng 9. So sánh kết quả được ghi nhận giữa Phase 1 và Phase 2 [6].



Hình 6. Diễn biến cải thiện kết quả qua bốn mốc phát triển của hệ thống.

Biểu đồ ở Hình 6 cho thấy hiệu năng được cải thiện qua từng giai đoạn. Từ baseline ban đầu, PCA vừa giảm mạnh số chiều từ 1.812 xuống 569 vừa tăng nhẹ Validation Macro F1. Sau đó, minority augmentation tiếp tục nâng Validation Macro F1 lên 95,77% và giúp cải thiện khả năng nhận diện lớp

hiếm. Ở giai đoạn cuối, việc chuyển từ RBF SVM sang Linear SVM trên không gian đặc trưng đã được chuẩn hóa và giảm chiều tạo ra bước nhảy lớn nhất, đưa Validation Macro F1 lên 97,30% và Test Macro F1 lên 96,29%.



Hình 7. Đối chiếu các metric giữa Phase 1 và Phase 2.

Linear SVM tăng Macro F1 0,65 điểm phần trăm và Macro Recall 1,23 điểm phần trăm, trong khi Accuracy giảm 0,12 và Macro Precision giảm 0,57. Đây là trade-off hợp lý trong dữ liệu mất cân bằng: mô hình nhận diện tốt hơn các lớp khó và giảm false negative, đổi lại phát sinh thêm một số false positive. Vì Macro F1 là metric chính, Linear SVM được chọn làm mô hình cuối.

6.7. Phân tích nhóm lỗi còn lại

Cặp / nhóm lớp	Đặc điểm gây nhầm	Nguyên nhân khả dĩ	Hướng xử lý
P.127_60 ↔ P.127_80	Cùng biển tròn viền đỏ, khác chữ số	Chi tiết số nhỏ, mờ hoặc nén bởi PCA	Crop vùng số; đặc trưng độ phân giải cao; classifier chuyên biệt
W.224 ↔ W.245a	Cùng tam giác nền vàng, biểu tượng đen	Hình dạng tổng thể giống; biểu tượng trung tâm nhỏ	Đặc trưng local; multi-stage classification

Cặp / nhóm lớp	Đặc điểm gây nhầm	Nguyên nhân khả dĩ	Hướng xử lý
P.130 ↔ P.131a	Cấu trúc hình học gần giống, khác hướng ký hiệu	Lệch góc và blur làm mất hướng	Augmentation góc nhìn; orientation-sensitive local features
W.205c	Lớp cực hiếm	17 ảnh train, biến thiên test chưa được đại diện	Thu thập dữ liệu thật; few-shot/metric learning trong tương lai

Bảng 10. Các nhóm lỗi tiêu biểu và hướng khắc phục.

Các lỗi trên cho thấy giới hạn không nằm hoàn toàn ở bộ phân loại. Khi hai lớp có cùng hình dạng và màu sắc, phần thông tin quyết định thường chỉ nằm ở một vùng rất nhỏ. Nếu vùng này bị mờ, nén hoặc chiếm quá ít pixel, cả HOG và histogram màu đều khó cung cấp tín hiệu đủ mạnh. Vì vậy, tăng độ phức tạp của classifier chưa chắc giải quyết được nguyên nhân gốc.

W.205c minh họa rõ small-sample problem: chỉ 17 ảnh train không đủ bao phủ các góc nhìn và điều kiện ảnh khác nhau. Hướng ưu tiên nên là bổ sung dữ liệu thật và đánh giá per-class ổn định hơn, trước khi áp dụng các mô hình phức tạp hoặc kỹ thuật tổng hợp mạnh.

7. THẢO LUẬN

7.1. Vì sao HOG và HSV bổ sung cho nhau?

HOG tập trung vào hình dạng, đường viền và biểu tượng; HSV Histogram mô tả phân bố màu tổng thể. Hai biến có hình dạng giống nhau nhưng màu khác có thể được tách nhờ HSV, trong khi hai biến cùng màu nền nhưng biểu tượng khác nhau được tách nhờ HOG. Sự bổ sung này phù hợp với cấu trúc thiết kế của biến báo giao thông. Tuy nhiên, ablation M03 cho thấy fusion không tự động tốt hơn HOG đơn lẻ; lợi ích chỉ xuất hiện khi xét cả pipeline cùng PCA và augmentation.

7.2. Vai trò thực nghiệm của PCA

PCA giảm bộ nhớ, số phép tính và độ trễ, đồng thời cải thiện nhẹ Macro F1 trong M04. Tuy nhiên, PCA tối đa hóa phương sai chứ không tối ưu trực tiếp

khả năng phân lớp. Một số chi tiết có phương sai nhỏ nhưng quan trọng cho nhãn, ví dụ nét chữ số, có thể bị suy giảm khi nén. Vì vậy, kết luận đúng là “PCA hiệu quả trên bộ đặc trưng và split này”, không phải “PCA luôn loại bỏ nhiễu và luôn tăng độ chính xác”.

7.3. Vì sao Linear SVM tốt hơn RBF trong pipeline này?

Kết quả Logistic Regression và Linear SVM cho thấy dữ liệu sau Standard-Scaler và PCA có khả năng phân tách tốt bằng ranh giới tuyến tính. Khi đó, RBF thêm độ linh hoạt không cần thiết và có thể nhạy hơn với tham số. $C=0,1$ tạo soft margin rộng hơn, giảm nhạy với outlier và ảnh biến dạng. Kết luận chỉ áp dụng cho pipeline HOG+HSV+PCA hiện tại; không thể suy rộng rằng Linear SVM luôn tốt hơn RBF trong mọi bài toán biến báo.

Về triển khai, SVC kernel tuyến tính vẫn có thể dựa trên support vectors trong quá trình dự đoán tùy cách hiện thực của thư viện. Vì vậy báo cáo sử dụng thời gian đo thực tế và số support vector, không đơn giản hóa thành giả định rằng dự đoán chắc chắn chỉ là một phép $w^T x + b$ duy nhất trong mọi implementation.

7.4. Vì sao Random Forest và LightGBM thấp hơn?

Cây quyết định chia không gian bằng các ngưỡng theo từng chiều. Sau PCA, mỗi chiều là tổ hợp tuyến tính của nhiều đặc trưng gốc; ranh giới lớp có thể nằm theo hướng chéo và cần nhiều phép chia để xấp xỉ, tạo vùng quyết định phân mảnh. Đây là một giải thích hợp lý cho việc Random Forest và LightGBM thấp hơn SVM 8,7-10,6 điểm Macro F1, nhưng nên được xem là giả thuyết dựa trên đặc trưng của mô hình và kết quả, không phải chứng minh duy nhất.

7.5. Hạn chế của KNN trong 571 chiều

KNN dựa vào khoảng cách giữa mẫu. Trong không gian cao chiều, khoảng cách có xu hướng ít phân biệt hơn và dự đoán phải so sánh với nhiều mẫu train. PCA đã giảm chiều đáng kể nhưng 571 vẫn cao. KNN đạt Macro F1 94,23%, cho thấy đặc trưng có chất lượng, nhưng không vượt SVM và classifier inference khoảng 1,81 ms/ảnh.

7.6. Ý nghĩa của việc tăng Macro Recall

Phase 2 giảm nhẹ Accuracy và Precision nhưng tăng Recall. Trong ứng dụng biến báo, bỏ sót một biển hiểm có thể nghiêm trọng hơn một số false

positive bổ sung, tùy kịch bản triển khai. Macro Recall tăng 1,23 điểm cho thấy mô hình quan tâm tốt hơn đến các lớp khó. Tuy nhiên, để kết luận về an toàn, cần đánh giá theo chi phí lỗi của từng lớp và trên dữ liệu đường phố thực tế, không chỉ dựa vào metric trung bình.

7.7. Khả năng triển khai

Classifier inference 1,52 ms/ảnh tương đương khoảng 658 dự đoán/giây nếu chỉ xét bước phân loại. Đây không phải FPS end-to-end. Dù vậy, kết quả cho thấy classifier không phải nút thắt lớn và pipeline có tiềm năng thời gian thực nếu HOG, HSV và PCA được tối ưu. Cần đo trên phần cứng mục tiêu, báo cáo RAM, kích thước model và độ trễ từng stage trước khi khẳng định khả năng triển khai edge.

8. HẠN CHẾ VÀ ĐE DỌA TÍNH HỢP LỆ

8.1. Hạn chế dữ liệu

- Một số lớp có quá ít ảnh, khiến metric per-class có phương sai cao và khó khái quát.
- Ảnh đã crop nên chưa đánh giá sai số detection, background clutter và multiple signs.
- Augmentation mới bao phủ xoay và sáng nhẹ; chưa bao phủ perspective, motion blur, occlusion và weather.
- Một split duy nhất chưa đủ để ước lượng độ ổn định của mô hình.

8.2. Hạn chế protocol

- Các artifact đã quan sát test ở nhiều giai đoạn; test không còn là blind holdout tuyệt đối.
- Một số benchmark M05 dùng cột tên "Test", vì vậy cần tránh sử dụng chính các kết quả đó để lựa chọn lặp lại mà không có validation độc lập.
- Chưa báo cáo khoảng tin cậy hoặc kiểm định thống kê cho chênh lệch 0,65 điểm Macro F1.
- Thời gian train/inference có thể không so sánh trực tiếp nếu các bước đo hoặc phần cứng khác nhau.

8.3. Hạn chế tái lập và nhất quán artifact

- Số chiều 1.812 được lấy từ artifact M04 nhưng chưa khớp hoàn toàn với decomposition lý thuyết từ các tham số HOG được ghi lại.
- Cần lưu phiên bản thư viện, seed, phần cứng, mã hash dữ liệu và command chạy cuối để tái lập đầy đủ.
- Con số 1,52 ms/ảnh chỉ là classifier inference; chưa có profiling end-to-end.
- Chưa báo cáo kích thước file model, peak RAM và thời gian khởi tạo pipeline.

9. HƯỚNG PHÁT TRIỂN

11. Thu thập thêm dữ liệu thật cho các lớp dưới 30 ảnh, ưu tiên W.205c và các lớp có per-class Recall thấp.
12. Xây dựng phân loại phân cấp coarse-to-fine: tầng đầu nhận diện nhóm hình dạng/màu, tầng sau xử lý các cặp dễ nhầm, tham khảo chiến lược của Ma và Huang [3].
13. Tách vùng trung tâm hoặc vùng chữ số ở độ phân giải cao cho nhóm biển tốc độ.
14. Mở rộng augmentation có kiểm soát với perspective transform, blur, contrast, occlusion và mô phỏng thời tiết.
15. Thực hiện repeated stratified cross-validation hoặc nested validation cho toàn pipeline; khóa test chỉ dùng một lần.
16. So sánh SVC linear với LinearSVC, SGDClassifier hoặc mô hình tuyến tính nén để giảm kích thước và latency.
17. Đo end-to-end latency, RAM và model size trên CPU/edge device, phân rã thời gian từng stage.
18. Kết hợp module phát hiện biển báo để tạo pipeline end-to-end trên ảnh đường phố.

10. KẾT LUẬN

Dự án đã xây dựng một pipeline nhận diện biển báo giao thông Việt Nam dựa trên computer vision truyền thống và học máy cổ điển. Pipeline cuối

gồm 64×64 pad_square, HOG Gray, HSV Color Histogram, StandardScaler, PCA giữ 95% phương sai, augmentation ảnh cho 10 lớp thiểu số và SVC tuyến tính với $C=0,1$.

Quá trình thực nghiệm được tổ chức theo hai giai đoạn. Phase 1 tối ưu tiền xử lý và đặc trưng với RBF cố định; Phase 2 benchmark sáu họ mô hình và tinh chỉnh SVM. Cấu hình cuối đạt Accuracy 96,12%, Macro F1 96,29%, Macro Recall 95,62% và classifier inference 1,52 ms/ảnh trên tập test 851 ảnh. So với RBF Phase 1, Linear SVM tăng Macro F1 0,65 điểm phần trăm và Macro Recall 1,23 điểm phần trăm, đồng thời giảm 817 support vector.

Kết quả chứng minh rằng thiết kế biểu diễn có thể quan trọng hơn việc tăng độ phức tạp mô hình. HOG và HSV cung cấp thông tin bổ sung; PCA giảm mạnh số chiều; augmentation giúp lớp hiếm; và Linear SVM phù hợp tốt với không gian sau biến đổi. Đồng thời, báo cáo xác định rõ các giới hạn về repeated test exposure, latency chưa end-to-end, lớp cực hiếm và sự chưa thống nhất số chiều artifact. Những điểm này tạo nền tảng minh bạch cho việc cải tiến và tái lập dự án trong giai đoạn tiếp theo.

Kết luận lựa chọn mô hình

Linear SVM được chọn không phải vì mọi chỉ số đều cao hơn RBF, mà vì nó tối ưu tiêu chí chính Macro F1, tăng Macro Recall, giảm số support vector và có classifier inference thấp hơn. Đây là một quyết định dựa trên trade-off, không phải chỉ dựa trên Accuracy.

TÀI LIỆU THAM KHẢO

[1] C. Cortes and V. Vapnik, "Support-vector networks," Machine Learning, vol. 20, pp. 273-297, 1995.

[2] N. Dalal and B. Triggs, "Histograms of oriented gradients for human detection," in Proc. IEEE CVPR, 2005, pp. 886-893.

[3] Y. Ma and L. Huang, "Hierarchical traffic sign recognition based on multi-feature and multi-classifier fusion," First International Conference on Information Science and Electronic Technology, 2015, pp. 56-59.

[4] J. Stallkamp, M. Schlipsing, J. Salmen, and C. Igel, "Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition," Neural Networks, vol. 32, pp. 323-332, 2012.

[5] R01, "Báo cáo tổng kết Phase 1-New: tối ưu hóa tiền xử lý và kỹ thuật đặc trưng," tài liệu nội bộ dự án, 05/07/2026.

[6] R02, "Báo cáo tổng kết Phase 2-New: khảo sát mô hình học máy và

ting chỉnh SVM,” tài liệu nội bộ dự án, 12/07/2026.

[7] M07, “Tài liệu tổng hợp và bàn giao cho Phase 3 Paper Writing,” tài liệu nội bộ dự án, 12/07/2026.

PHỤ LỤC A. CẤU HÌNH CUỐI CÙNG CỦA HỆ THỐNG

Thành phần	Cấu hình chốt
Dữ liệu	NVTS, 47 lớp; Train 6.605, Validation 824, Test 851
Tiền xử lý	64×64, pad_square
Đặc trưng hình dạng	HOG trên ảnh grayscale
Đặc trưng màu	HSV Color Histogram 8×8×8 bins
Dung hợp	Vector 1.812 chiều theo artifact M04
Chuẩn hóa	StandardScaler fit trên train
Giảm chiều	PCA 95% phương sai, 571 chiều final
Xử lý mất cân bằng	Augmentation ảnh 2D cho 10 lớp <30 mẫu; train tăng lên 7.035
Bộ phân loại	SVC kernel=linear, C=0,1, class_weight=None
Metric chính	Macro F1
Final result	Accuracy 96,12%; Macro F1 96,29%; Macro Recall 95,62%
Inference	1,52 ms/ảnh ở bước classifier trên đặc trưng đã xử lý

Bảng A1. Bộ tham số cuối cùng được sử dụng trong báo cáo.

PHỤ LỤC B. BẢNG KIỂM SOÁT TÍNH NHẤT QUÁN

Mục kiểm tra	Giá trị chuẩn	Ghi chú
Final Macro F1	96,29%	Dùng thống nhất trong Tóm tắt, Kết quả và Kết luận

Mục kiểm tra	Giá trị chuẩn	Ghi chú
Final Accuracy	96,12%	Không nhầm với 96,24% của Phase 1
Final Macro Recall	95,62%	Cải thiện +1,23 điểm phần trăm so với Phase 1
Classifier inference	1,52 ms/ảnh	Không ghi là end-to-end latency
PCA dimension	571	Vector final sau PCA ở pipeline cuối
Feature dimension	1.812	Theo artifact M04; cần audit code nếu công bố decomposition
Lớp hiếm	10 lớp <30 ảnh	Không khẳng định tất cả đều đạt 100%
Final model	SVC linear, C=0,1, class_weight=None	Cấu hình chốt M06
Test protocol	Đã quan sát ở nhiều artifact	Không mô tả là blind one-shot tuyệt đối

Bảng B1. Các giá trị cần giữ nhất quán khi chỉnh sửa hoặc trình bày.

PHỤ LỤC C. ARTIFACT NỘI BỘ PHỤC VỤ TÁI LẬP

Các đường dẫn dưới đây là artifact nội bộ của repository, không thay thế tài liệu tham khảo học thuật nhưng cần được lưu để truy vết số liệu:

- `paper/result/report_new/R01_26.07.05_report-phase1-new.md`
- `paper/result/report_new/R02_26.07.12_report-phase2-new.md`
- `paper/mission/phase3_new/M07_26-07-12_master_handover_document_for_paper_writing.md`
- `paper/workspace/TruongDT/phase2_new/outputs/M05_ml_models_comparison_results.csv`
- `paper/workspace/KietBA/phase2_new/outputs/M06_svm_finetuning_results.csv`
- `paper/workspace/KietBA/phase2_new/outputs/M06_final_test_summary.csv`

C.1. Checklist tái lập trước khi nộp

- Lưu requirements.txt hoặc environment.yml kèm phiên bản Python và thư viện.
- Lưu random seed, cách chia dữ liệu và hash của các file metadata/split.
- Lưu model, StandardScaler, PCA và cấu hình feature extraction theo cùng một version.
- Lưu command hoặc notebook dùng để tạo từng bảng kết quả trong báo cáo.
- Chạy lại pipeline từ dữ liệu đầu vào đến metric cuối trên một môi trường sạch.
- Đối chiếu số chiều HOG thực tế với artifact 1.812 trước khi công bố decomposition.